

Assimilação de dados por aprendizado de máquina

Haroldo F. de Campos Velho - INPE

Helaine C. M. Furtado - UFOPA

Juliana A. Anochi - INPE

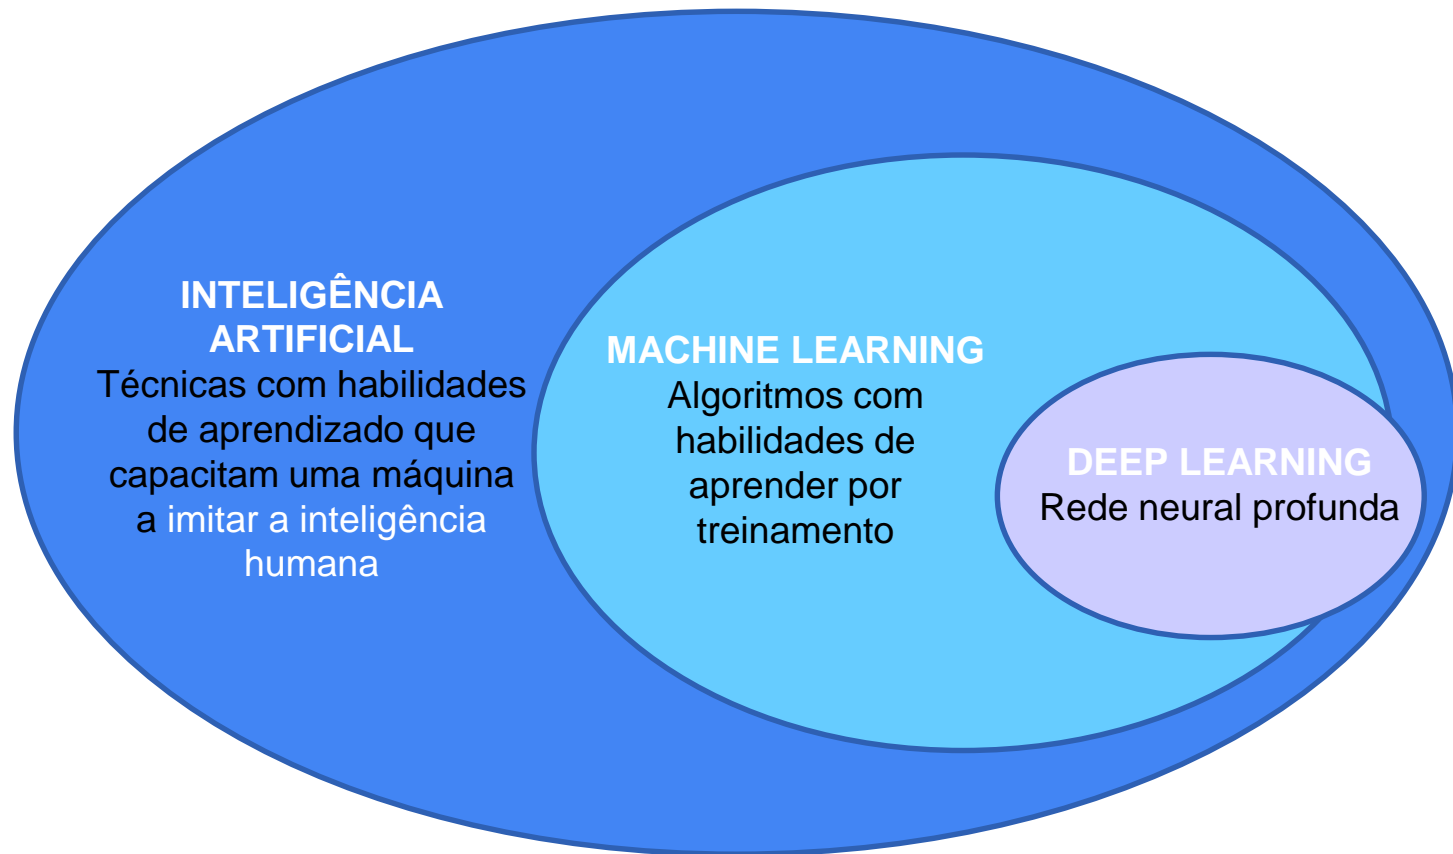
Roberto P. Souto - LNCC

Marcelo Paiva - INPE

Geronimo Lemos - INPE

- O que é "assimilação de dados"?
 - O porque da necessidade e breve histórico
- Métodos de assimilação de dados
 - *Nudging* e Métodos Variacionais
 - Filtro de Kalman e filtro de Kalman por conjunto
- Aprendizado de máquina
 - Breve descrição: MLP, Recorrente, Deep Learning
 - Pacote TensorFlow: (1) Lorenz; (2) Modelo Fluidity
 - Pacote XGBoost: Método variacional 3DVAR
- Aplicações
 - Modelos de baixa ordem: Lorenz-63, *shallow water* 1D e 2D
 - Processamento paralelo para assimilação com redes neurais
 - Modelos atmosféricos 3D: WRF (regional), SPEED e FSU (globais)

Inteligência Artificial



Inteligência Artificial

INTELIGÊNCIA ARTIFICIAL

Técnicas com habilidades
de aprendizado que
capacitam uma máquina
a imitar a inteligência
humana

VOL. LIX. No. 236.]

[October, 1950

M I N D

A QUARTERLY REVIEW

OF

PSYCHOLOGY AND PHILOSOPHY



I.—COMPUTING MACHINERY AND INTELLIGENCE


BY A. M. TURING

1. *The Imitation Game.*

Teste de Turing 1950

Jogo da imitação

1. **Configuração**
 - Um juiz humano faz perguntas a dois participantes. As respostas são trocadas via texto.
2. **Objetivo**
 - A máquina deve gerar respostas convincentes para enganar o juiz, fazendo-o acreditar que está conversando com um humano.
3. **Critério de Aprovação**
 - Se a máquina conseguir convencer o juiz em uma proporção significativa, considera-se que ela passou no Teste de Turing.



Chatbot 1966



ChatGPT 2018



Fonte: ChatGPT

O que é uma rede neural artificial?




Reproduzir
→
Inteligência humana

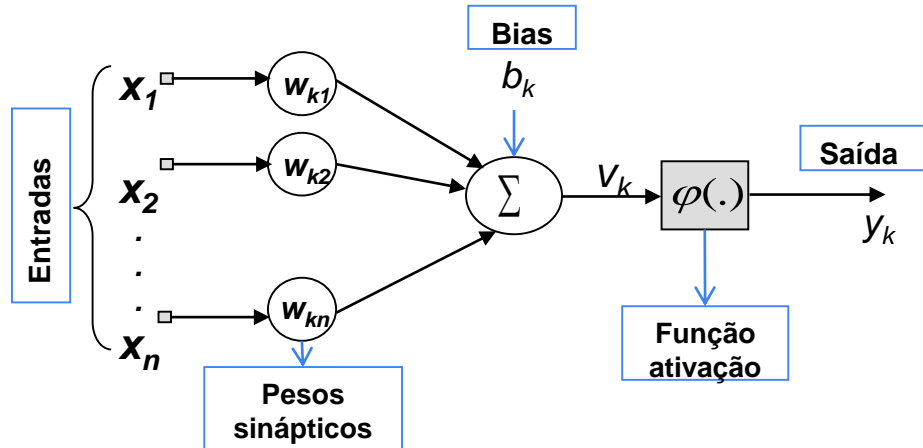


- **Aprendizado**: adquire conhecimento através de amostras de treinamento.
- **Armazenamento**: reuni todo o conhecimento (conexões sinápticas).
- **Adaptação**: ajustando-se a uma nova realidade (nova amostra de informação).

Inspiração biológica



Neurônio biológico

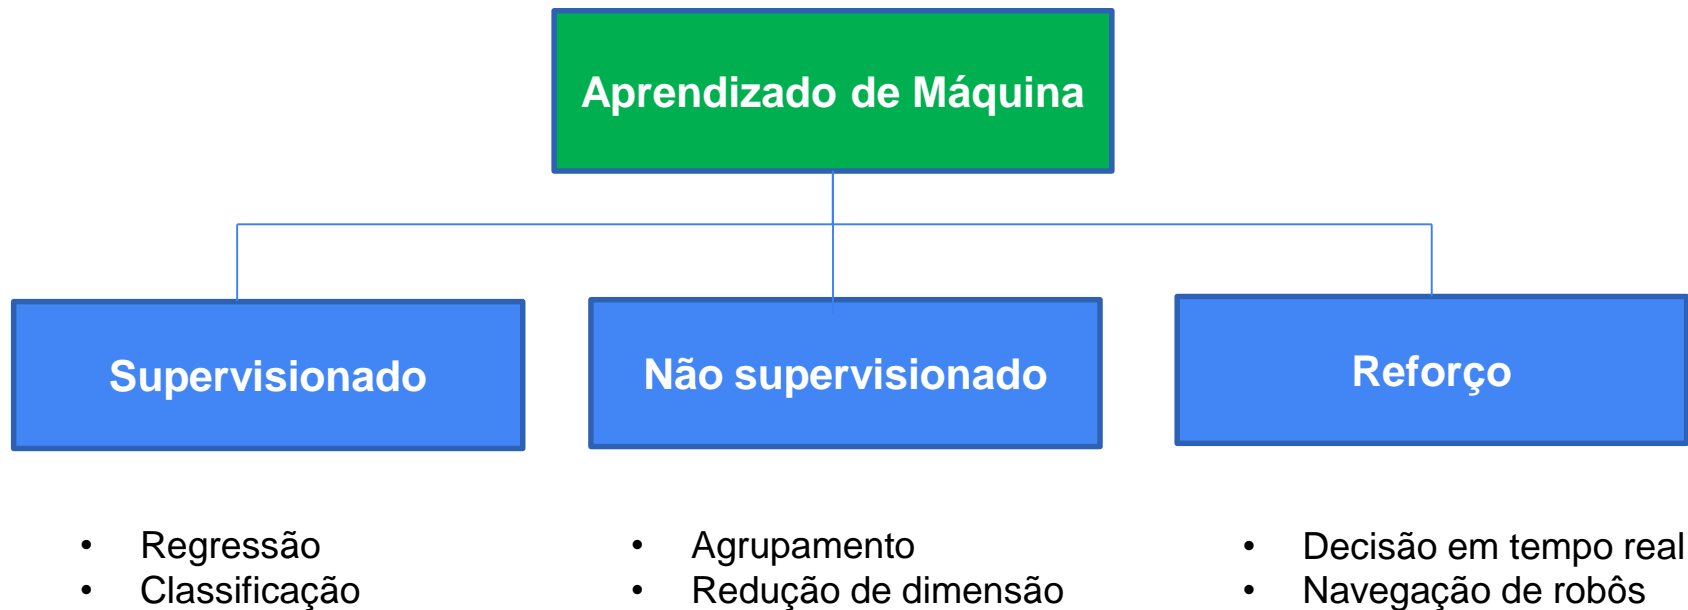


Neurônio artificial

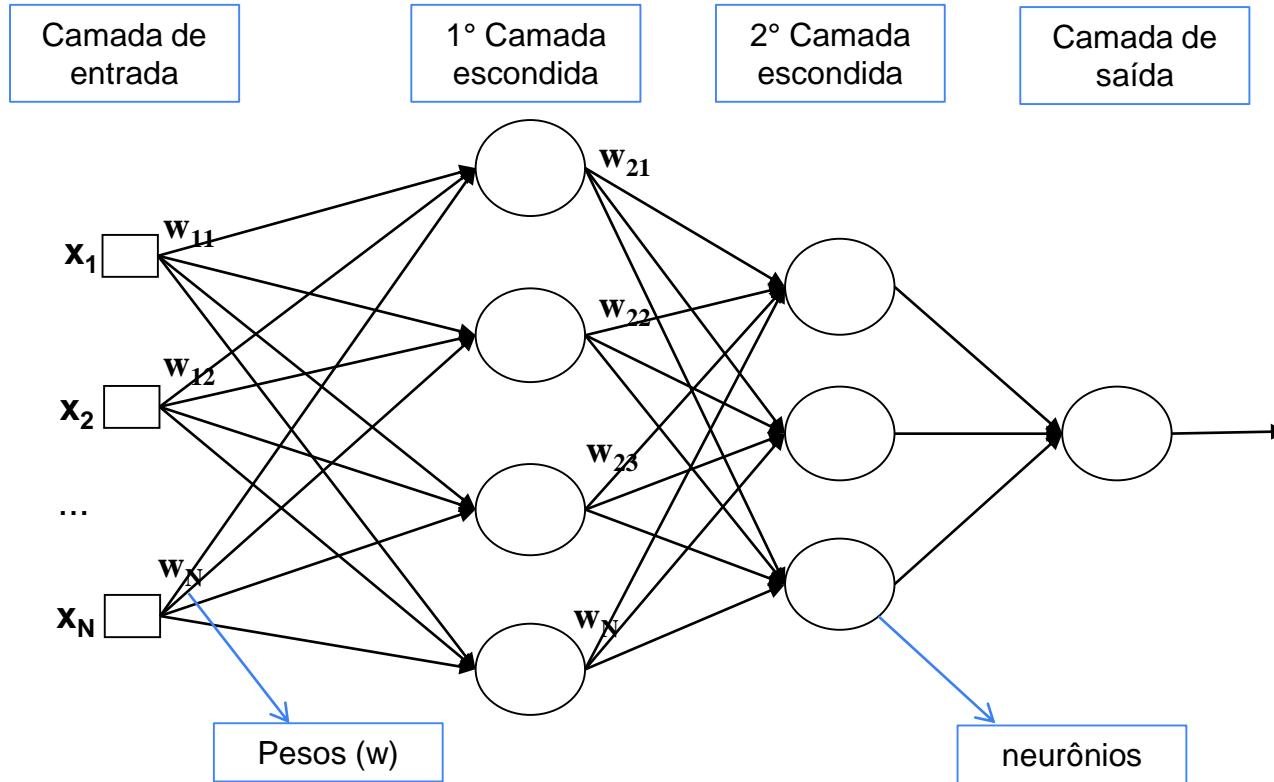
$$v_j(n) = \sum_{i=1}^p x_i w_{ij} + b_i$$

$$y_j(n) = \varphi_j(v_j(n))$$

Aprendizado de máquina

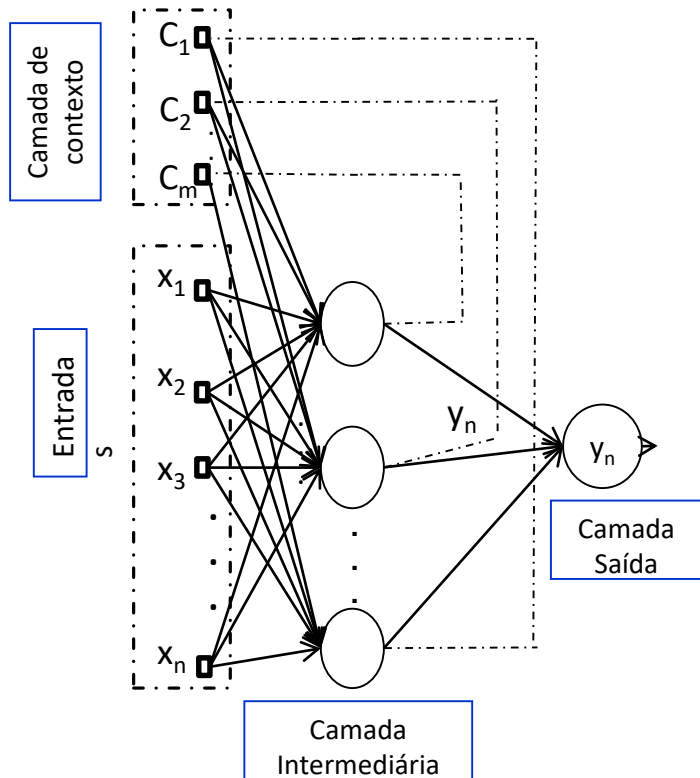


Perceptron de Múltiplas Camadas (MLP)

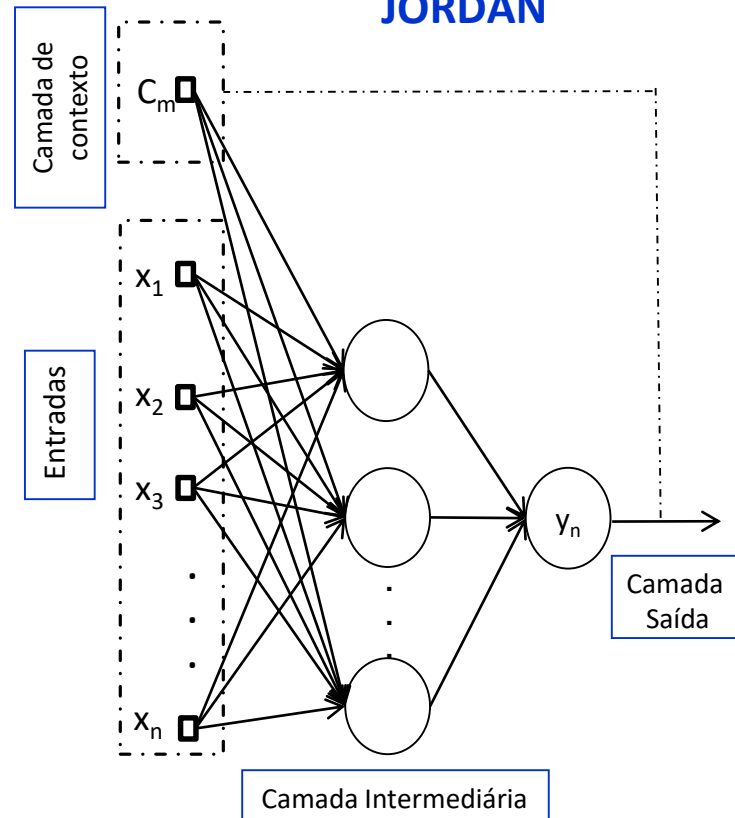


Redes recorrentes

ELMAN




JORDAN



Hiperparâmetros

- Os **hiperparâmetros** são configurações ajustáveis que controlam o aprendizado do modelo, mas que não são aprendidas a partir dos dados.
- RNA: taxa de aprendizado, número de camadas, quantidade de neurônio em cada camada, função de ativação, entre outros.
- Floresta Aleatória: número de árvores que será considerado.



Problema: como definir os hiperparâmetros?



- **Métodos**
 - Busca Exaustiva:
 - Busca Aleatória
 - Otimização Bayesiana
 - Metaheurísticas
 - Abordagem Empírica

Solução: Metaheurística

TRATAR COMO UM PROBLEMA DE OTIMIZAÇÃO



ENCONTRAR O MELHOR CONJUNTO DE PARÂMETROS QUE
OTIMIZEM UMA FUNÇÃO OBJETIVO



Disponível para download:

www.epacis.net/jcis/PDF_JCIS/JCIS11-art.01.pdf



Journal of Computational Interdisciplinary Sciences (2008) 1(1): 3-10
© 2008 Pan-American Association of Computational Interdisciplinary Sciences
ISSN 1983-8409
<http://epacis.org>

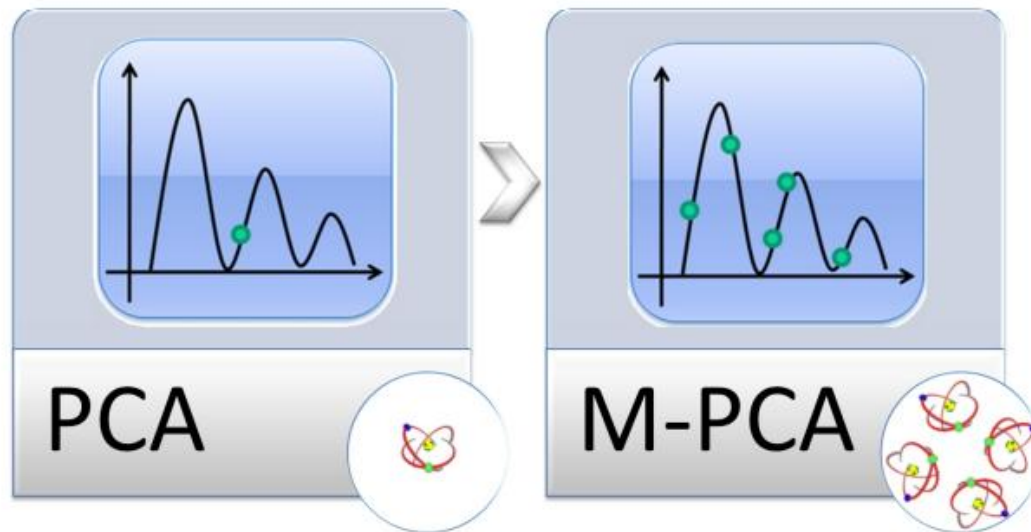
A new multi-particle collision algorithm for optimization in a high performance environment

Eduardo Fávero Pacheco da Luz, José Carlos Becceneri and Haroldo Fraga de Campos Velho

Manuscript received on July 31, 2008 / accepted on October 5, 2008



Algoritmo de Colisão de Múltiplas Partículas (MPCA)



Fonte: Luz, 2012

- O PCA explora o espaço de busca com uma única partícula.
- O MPCA, simula a adoção de n -partículas na exploração colaborativa do espaço de buscas, apresentando ganho de performance.

Gera uma solução inicial: Old_Config

Best_Fitness = Fitness(Old_Config)

Para n=0 **até** # de iterações

Para p=0 **até** # de partículas

Perturbation()

Se Fitness(New_Config) > Fitness(Old_Config)

Se Fitness(New_Config) > Best_Fitness

Best_Fitness := Fitness(New_Config)

Fim-se

Old_Config = New_Config

Exploration()


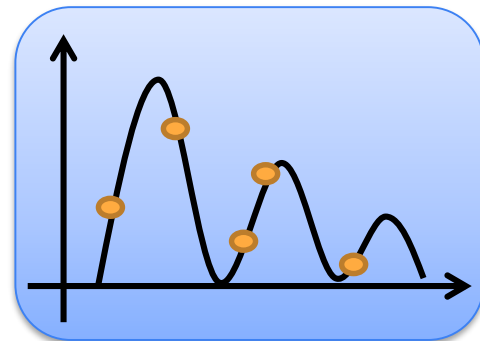
Senão

Scattering()

Fim-se

Fim-para

Fim-para



Algoritmo de Colisão de Múltiplas Partículas (MPCA)

Parâmetro	Intervalo de Valores
Número de camadas ocultas	[1, 2]
Neurônios por camada	[1, 100]
Taxa de aprendizado	[0.01, 0.9]
Momentum	[0.01, 0.9]
Função de ativação	Tangente Logística Gaussiana

$$F_{obj} = \underset{\downarrow}{penalty} * \frac{[\rho_1 * E_{train} + \rho_2 * E_{gen}]}{\rho_1 + \rho_2}$$

$$penalty = \underbrace{\left(c_1 * \left(e^{\#neuron} \right)^2 \right)}_{\text{complexity factor-1}} \times \underbrace{\left(c_2 * (\#epoch) \right)}_{\text{complexity factor-2}} + 1$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Aplicações usando RNA&MPCA

- Aplicações RNA&MPCA
 - Assimilação de dados (Furtado, 2012)
 - Previsão climática (Anochi, 2021)
 - Estimação de temperatura (Perfil atmosférico) (Sambati, 2012)
 - Navegação autônoma de Vant (Braga, 2018)
- RNA&MPCA está disponível para download:
 1. <https://github.com/scsr-inpe/mpca-ann>
 2. <https://github.com/sabrinabms/RNA-MPCA>

- O que é "assimilação de dados"?
 - O porque da necessidade e breve histórico
- Métodos de assimilação de dados
 - *Nudging* e Métodos Variacionais
 - Filtro de Kalman e filtro de Kalman por conjunto
- Aprendizado de máquina
 - Breve descrição: MLP, Recorrente, Deep Learning
 - Pacote TensorFlow: (1) Lorenz; (2) Modelo Fluidity
 - Pacote XGBoost: Método variacional 3DVAR
- Aplicações
 - Modelos de baixa ordem: Lorenz-63, *shallow water* 1D e 2D
 - Processamento paralelo para assimilação com redes neurais
 - Modelos atmosféricos 3D: WRF (regional), SPEED e FSU (globais)