



[MT04] Assimilação de dados por aprendizado de máquina

Assimilação de Dados por aprendizado de máquina

Haroldo F. de Campos Velho - INPE

Helaine C. M. Furtado - UFOPA

Juliana A. Anochi - INPE

Roberto P. Souto – LNCC

Gerônimo – UFPEL


Marcelo Paiva - INPE

Mini-curso: Assimilação de Dados por Redes Neurais

- O que é "assimilação de dados"?
 - O porque da necessidade e breve histórico
- Métodos de assimilação de dados
 - *Nudging* e Métodos Variacionais
 - Filtro de Kalman e filtro de Kalman por conjunto
- Redes neurais: breve descrição
 - Breve Descrição: MLP, Recorrente, Deep Learning
 - Árvore de decisão: Boosting e pacote XGBoost
 - Redes Neurais e Pacote Tensor Flow
- Aplicações
 - Modelos de baixa ordem: Lorenz-63, onda 1D shallow water 2D.
 - Processamento paralelo para assimilação com redes neurais
 - Modelos atmosféricos 3D: WRF (regional), SPEED e FSU (globais)

Aplicações

■ Sistema dinâmico de Lorenz




$$\dot{x} = \sigma(y - x) \quad (1)$$

$$\dot{y} = \rho x - y - xy \quad (2)$$

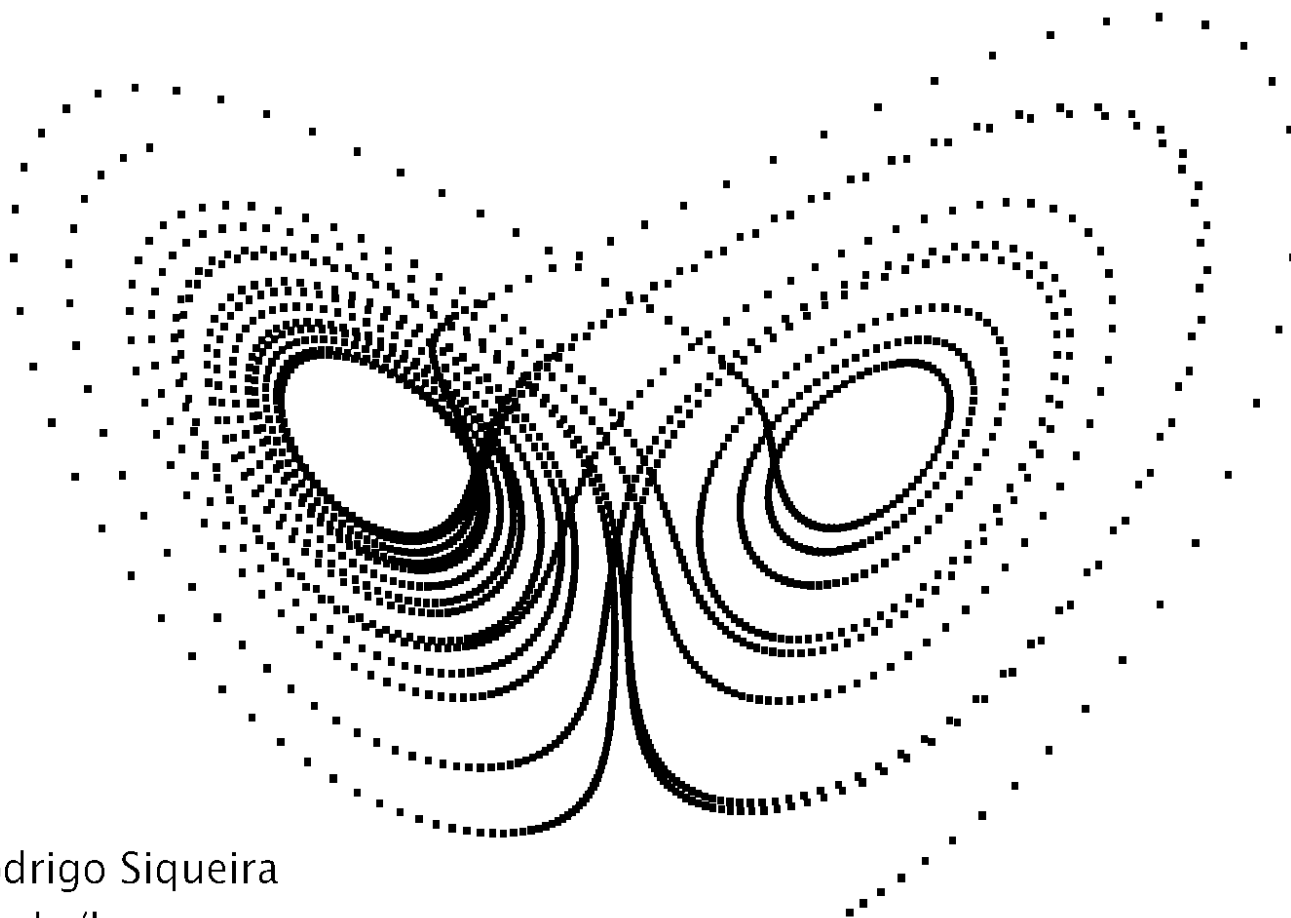
$$\dot{z} = xy - \beta z \quad (3)$$

onde: $\sigma = 10$, $\rho = 28$, $\beta = 8/3$ são parâmetros do modelo.



Disponível em https://commons.wikimedia.org/wiki/File:Lorenz_attractor.gif

- um atrator estranho - (o sistema flutua para sempre entre vários estados de um modo que não é aleatório, nem é fixo, nem oscilatório, mas sim uma flutuação contínua caótica).



Rodrigo Siqueira
[bit.do/lorenz](https://bit.ly/lorenz)

Disponível em:
<https://medium.com/@rodrigo.siqueira/a-borboleta-do-caos-eb4db837cff6>

Efeito borboleta foi uma metáfora utilizada pelo meteorologista Edward Lorenz, professor do Instituto de Tecnologia Meteorológica de Massachusetts, para explicar a impossibilidade de previsão de fenômenos atmosféricos por mais que alguns dias.

Sensibilidade das condições iniciais




Figura: curva vermelha: condição inicial $x(0) = -1.4950$; curva azul: condição inicial $x(0) = -1.5$

O que é um sistema operacional de previsão?

QUAIS AS
APLICAÇÕES?



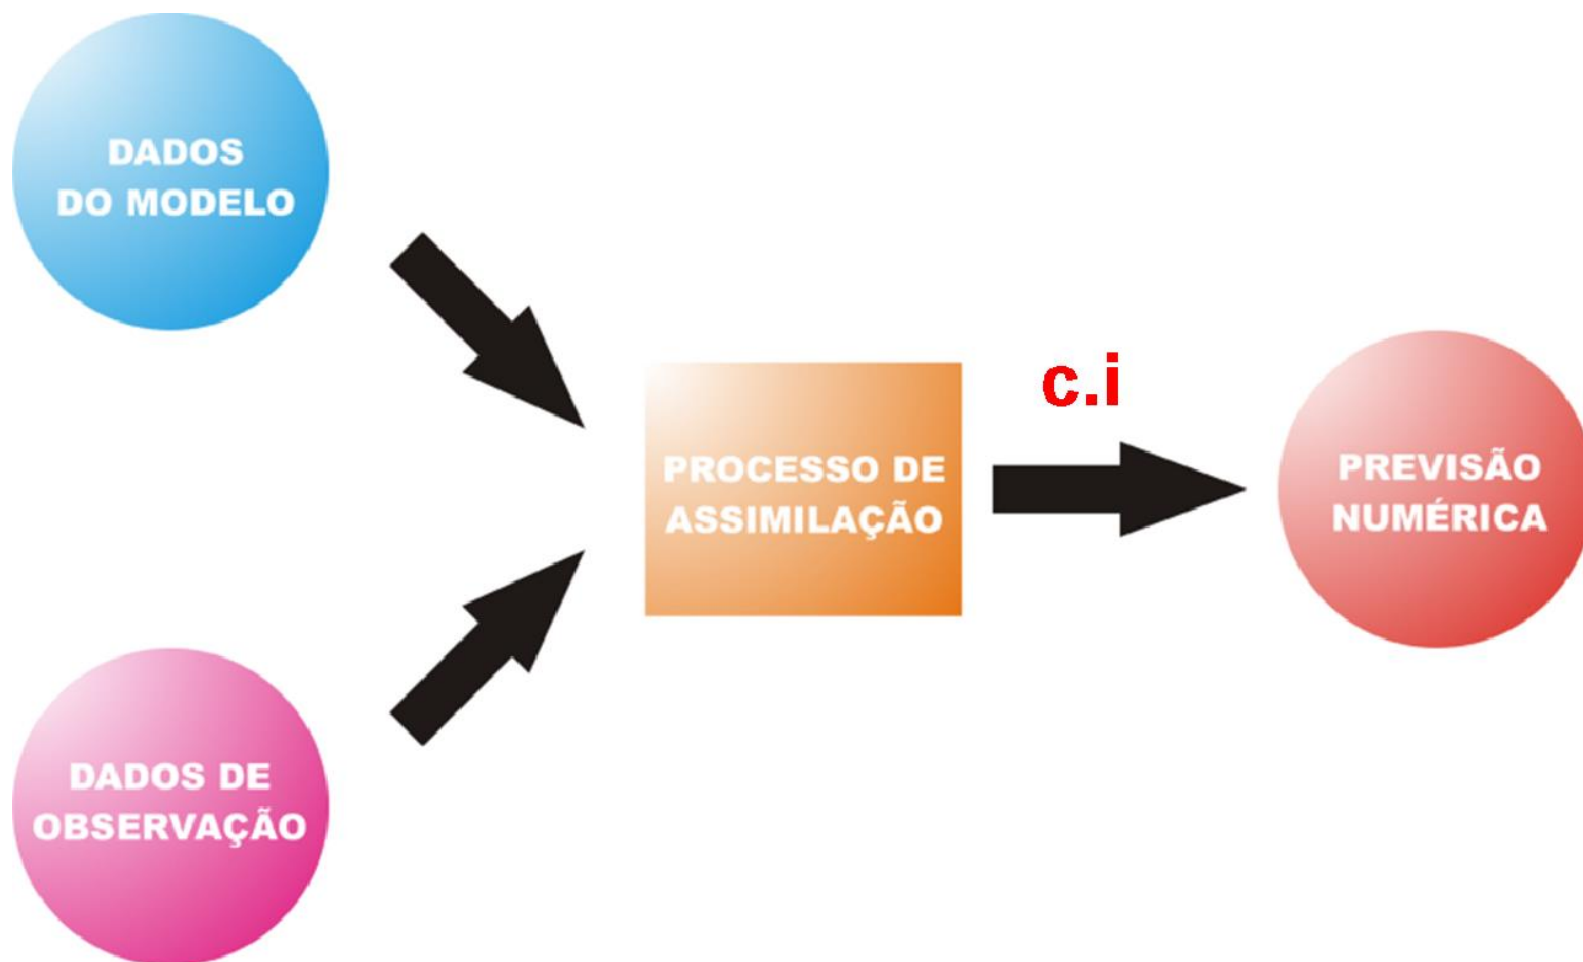
O que é um sistema operacional de previsão?


- É uma ferramenta que combina dados, algoritmos e tecnologia para prever eventos futuros e auxiliar na tomada de decisões.



Aplicações


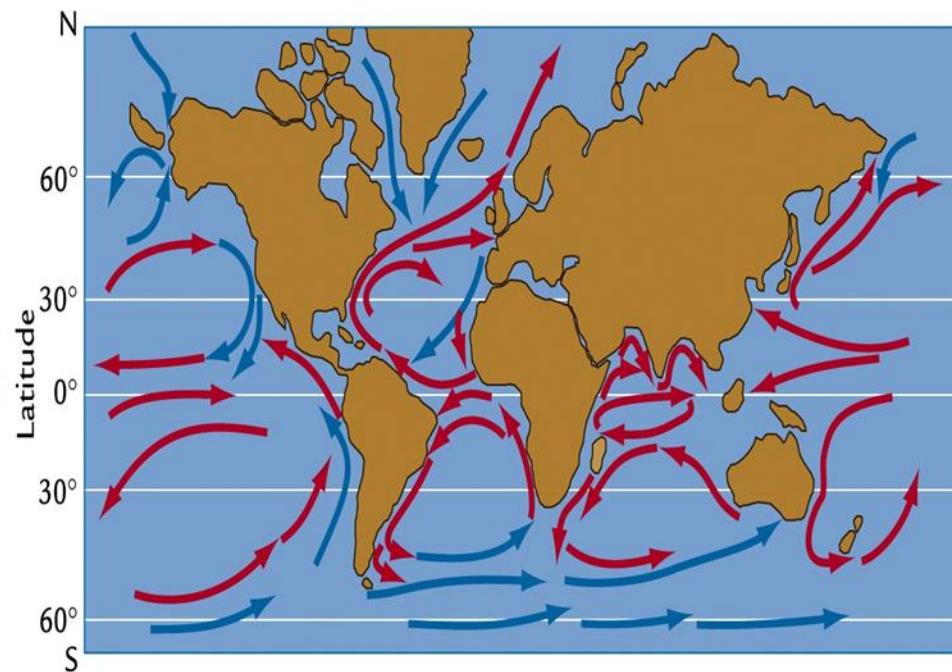

- Previsão de demanda (quantidade de produtos em empresas)
- Previsão Financeira
- Previsão de Saúde



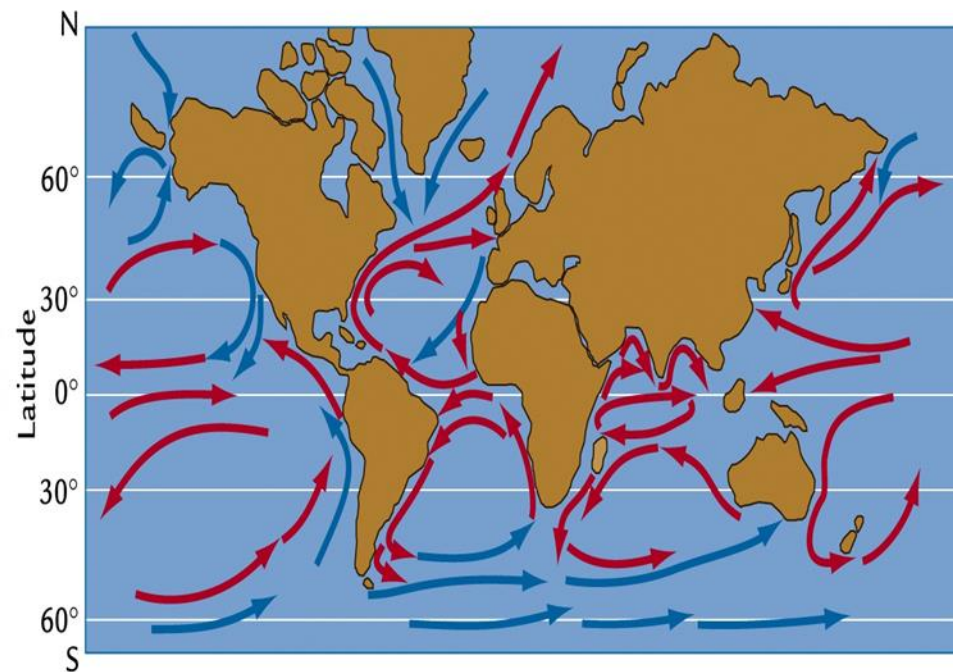

Assimilação de dados











Modelo

O modelo físico-matemático é sempre uma aproximação da realidade.


Observações

consistem de informações sobre o fenômeno que se deseja modelar.

$$\frac{\partial u}{\partial t} - fv + g \frac{\partial q}{\partial x} + r_u u = F_u$$

$$\frac{\partial v}{\partial t} + fu + g \frac{\partial q}{\partial y} + r_v v = F_v$$

$$\frac{\partial q}{\partial t} + H \left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} \right) + r_q q = 0$$







Horizontal Grid
(Latitude-Longitude)

Vertical Grid
(Height or Pressure)

Physical Processes in a Model



Modelos




PREVISÃO

Previsão para 21/11/2012



www.cptec.inpe.br





2. Técnicas de assimilação de dados

Matematicamente

Previsão

$$\mathbf{x}_t^p = \mathbf{F}(\mathbf{x}_{t-1}^a)$$

Análise

$$\mathbf{x}_t^a = \mathbf{x}_t^p + \boldsymbol{\rho}$$

em que $\boldsymbol{\rho}$ é a correção da análise

Como fazer a correção?

Correções Sucessivas

$$\begin{aligned} \mathbf{x}^{j+1}(i) &= \mathbf{x}^j(i) + \mathbf{W}[\mathbf{y}(i) - \mathbf{H}(\mathbf{x}^j(i))] \\ \mathbf{W} &= 0.5\mathbf{I} \text{ e } \mathbf{H} = \mathbf{I} \end{aligned}$$

Interpolação Ótima

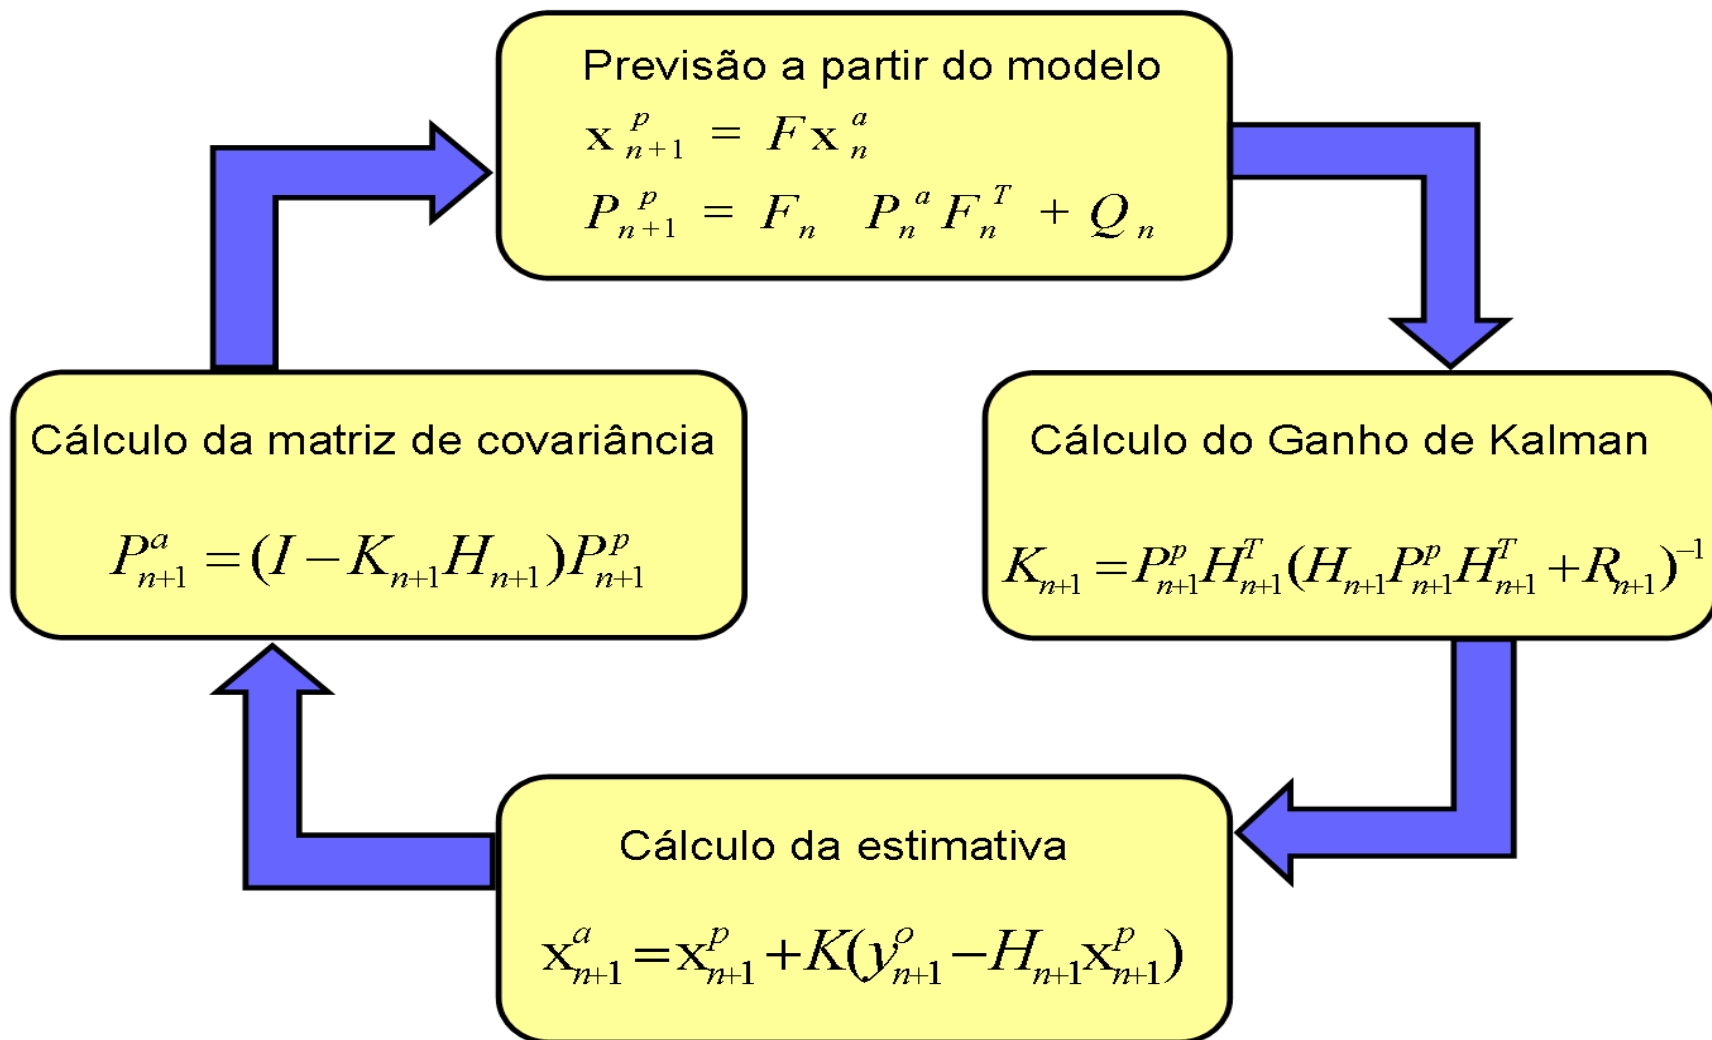
$$\begin{aligned} \mathbf{x}^a(i) &= \mathbf{x}^b(i) + \mathbf{W}[\mathbf{y}(i) - \mathbf{H}(\mathbf{x}^b(i))] \\ \mathbf{W} &= \mathbf{B}\mathbf{H}^T(\mathbf{H}\mathbf{B}\mathbf{H}^T + \mathbf{R})^{-1} \end{aligned}$$

Análise de Correções

$$\begin{aligned} \mathbf{x}^{j+1}(i) &= \mathbf{x}^j(i) + \mathbf{K}\mathbf{Q}[\mathbf{y}^j(i) - \mathbf{H}(\mathbf{x}^j(i))] \\ \mathbf{y}^{j+1}(i) &= \mathbf{y}^j(i) - \mathbf{Q}[\mathbf{y}^j(i) - \mathbf{H}(\mathbf{x}^j(i))] \\ \mathbf{K} &= \mathbf{B}\mathbf{H}^T\mathbf{R}^{-1} \\ \mathbf{Q} &= (\mathbf{H}\mathbf{K} + \mathbf{I})^{-1} \end{aligned}$$

Como fazer a correção?

■ Filtro de Kalman



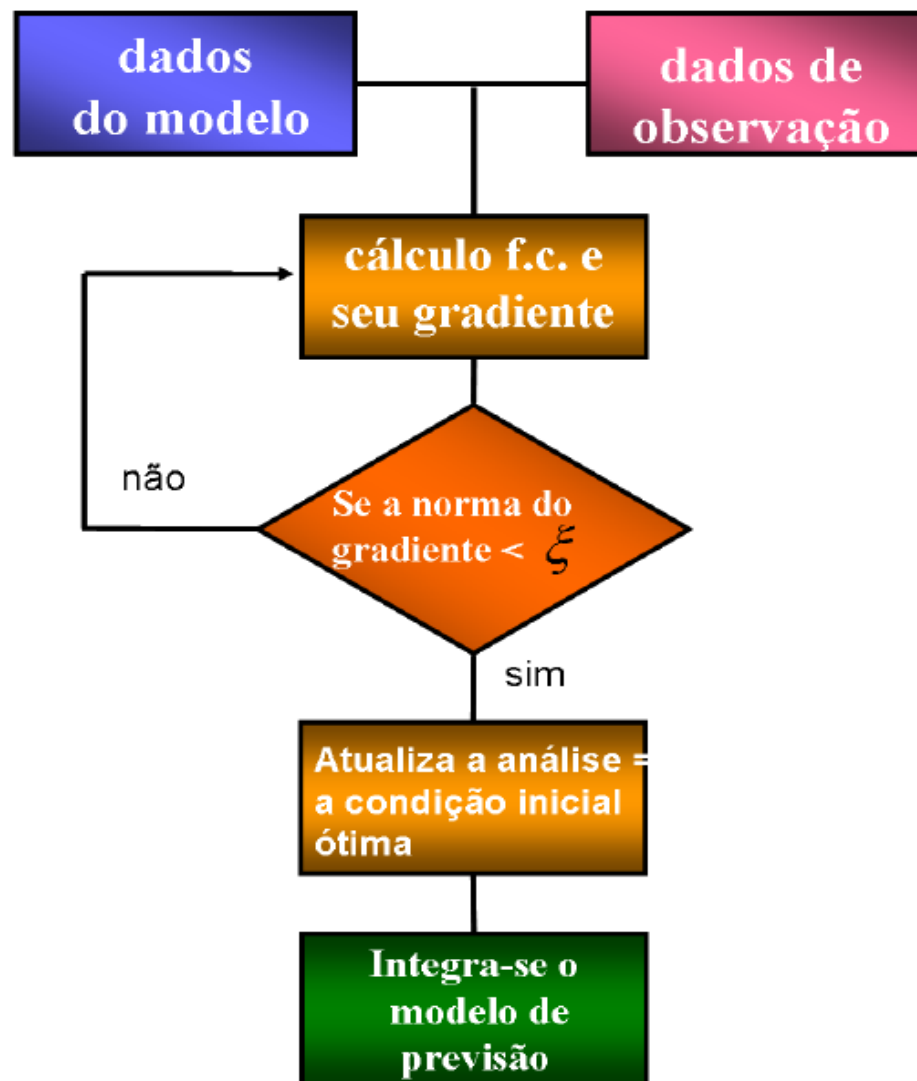
Como fazer a correção?

Método Variacional

Funcional

$$J(\mathbf{x}(t_0)) = \underbrace{\frac{1}{2}(\mathbf{x}(t_0) - \mathbf{x}^b(t_0))^T \mathbf{B}^{-1}(\mathbf{x}(t_0) - \mathbf{x}^b(t_0))}_{J_b} + \underbrace{\frac{1}{2} \sum_{i=0}^N (\mathbf{y}_i^o - \mathbf{H}(\mathbf{x}_i))^T \mathbf{R}^{-1}(\mathbf{y}_i^o - \mathbf{H}(\mathbf{x}_i))}_{J_o}$$

Algoritmo



Como fazer a correção?

Filtro de Partículas

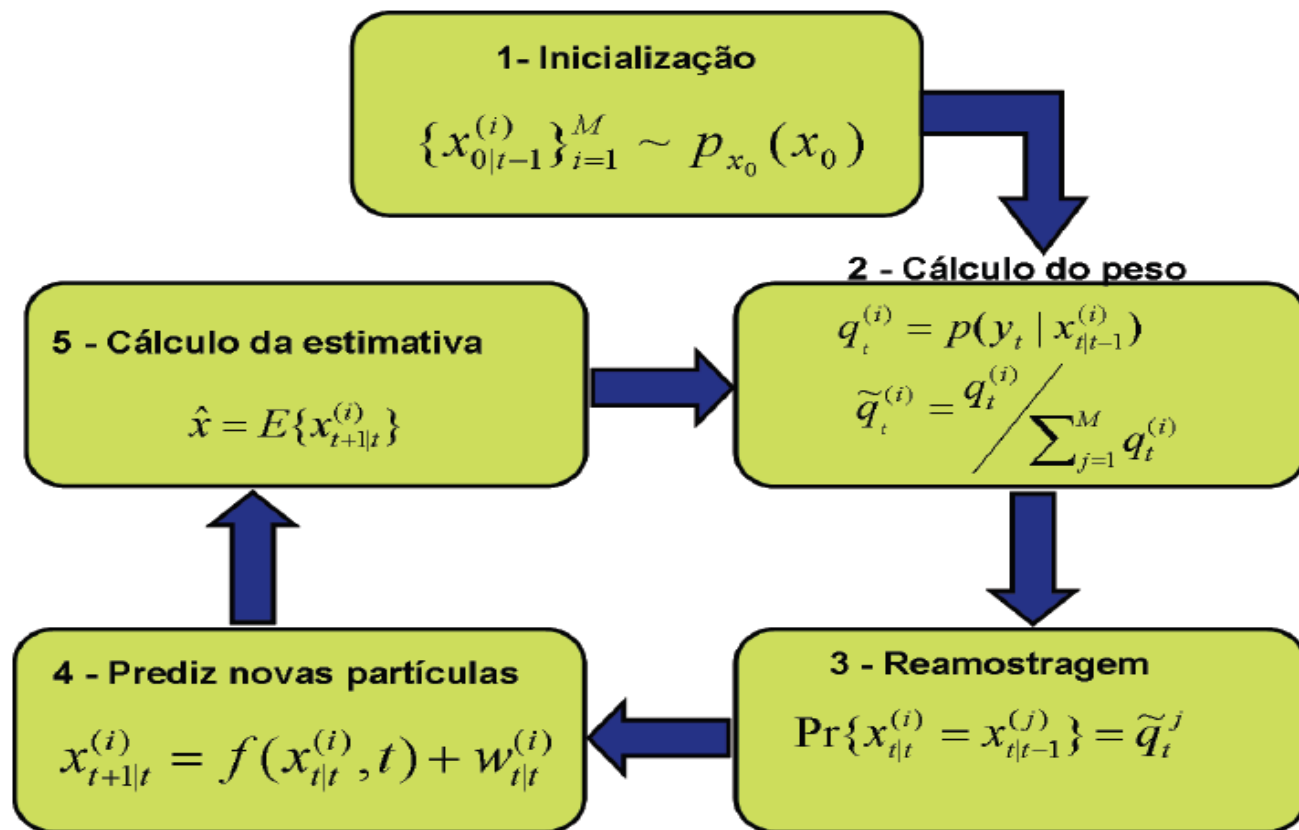


Figura: Diagrama esquemático do Filtro de Partículas.

Filtro de Partículas

1. Inicialização: Para $i = 1, \dots, M$ Inicializa-se as partículas:
 $\{x_{0|t-1}^{(i)}\}_{i=1}^M \sim p_{x_0}(x_0)$, $x_0^{(i)} \sim \mathcal{N}(0, 5)$ e $w_t^{(i)} \sim p_{w_t}(w_t)$ com $w_t \sim \mathcal{N}(0, 1)$

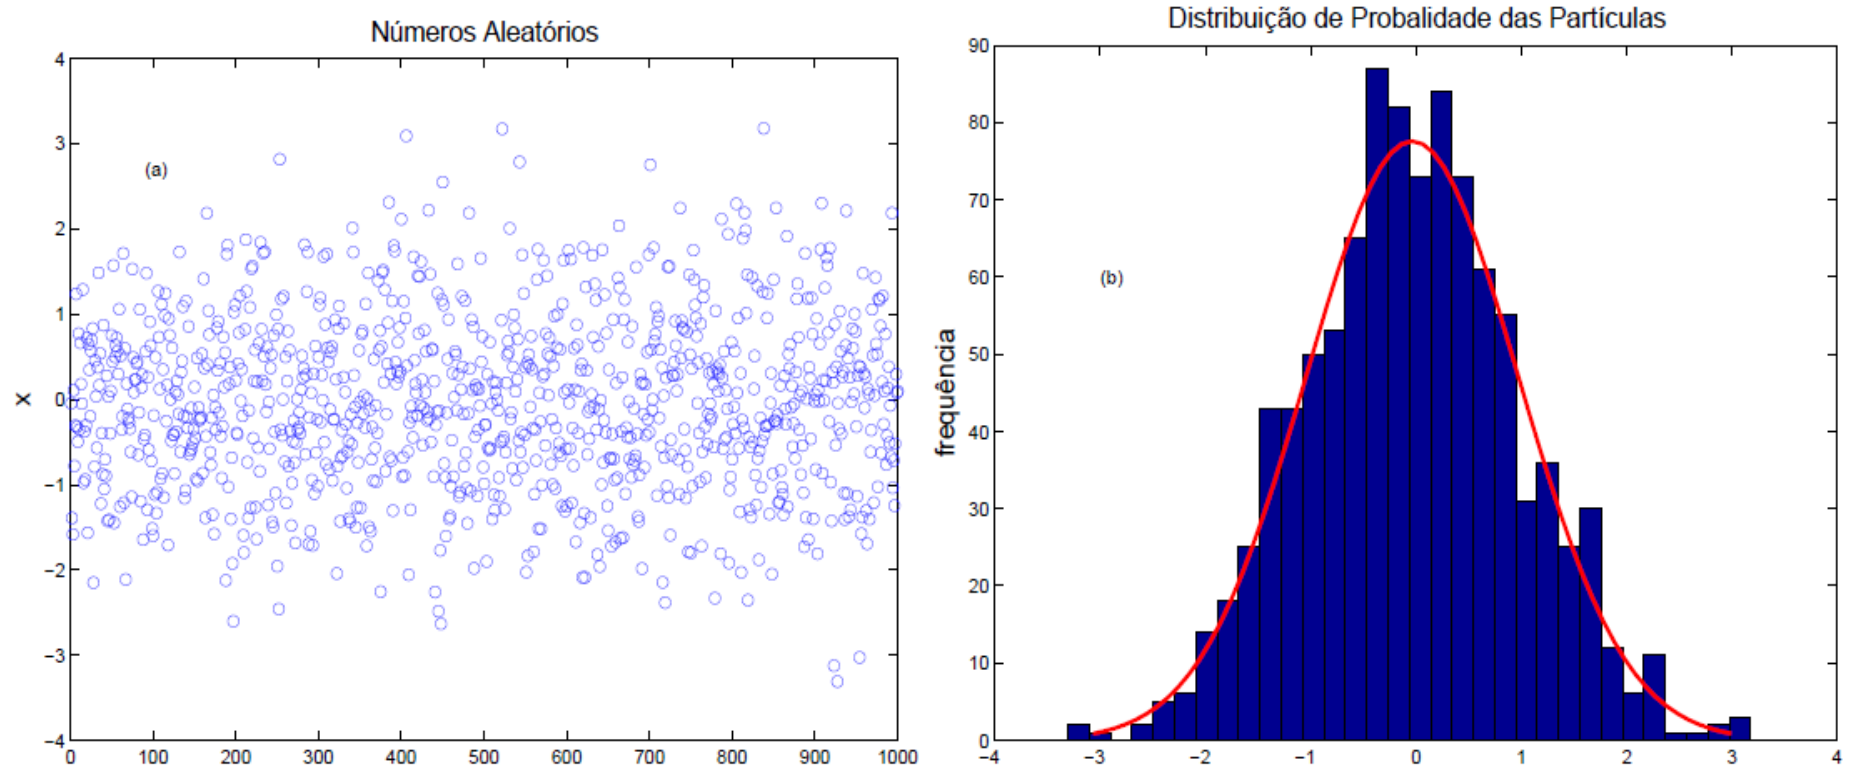


Figura: (a): partículas iniciais (números aleatórios); (b): distribuição de probabilidade das partículas iniciais.

Filtro de Partículas

2. Para $i = 1, \dots, M$ Calcula-se o **peso de importância** $\{q_t^{(i)}\}_{i=1}^M$.

$z_t^{(i)} = (y_t - h(x_t))$ é a inovação

$$q_t^{(i)} = p_{et}(z_t^{(i)}) = p_{et}(y_t | x_{t|t-1}^{(i)})$$

em que:

$$p_{et} = \frac{1}{\sigma_z \sqrt{2\pi}} e^{\frac{-(z - \bar{z})^2}{2\sigma_z^2}} \text{ com } \sigma_z^2 = \frac{1}{M-1} \sum z_t^{(i)} \text{ e } \bar{z} = \frac{1}{M} \sum_i z_t^{(i)}$$

normaliza $\tilde{q}_t^{(i)} = \frac{q_t^{(i)}}{\sum_{j=1}^M q_t^{(j)}}$

Filtro de Partículas

3. **Reamostragem:** Para $i = 1, \dots, M$

Tabela: Amostragem Sistemática

Algoritmo: Amostragem Sistemática

1. Gera-se M números ordenados de acordo com

$$u_k = \frac{(k-1) + \tilde{u}}{M}, \quad \tilde{u} \sim U(0, 1) \text{ e } k = 1, \dots, M$$

2. As partículas reamostradas são obtidas pela produção n_i cópias da partícula $x^{(i)}$, onde

$$n_i = \text{o número de } u_k \in \left(\sum_{s=1}^{i-1} \tilde{q}_t^{(s)}, \sum_{s=1}^i \tilde{q}_t^{(s)} \right]$$

Filtro de Partículas

4. Para $i = 1, \dots, M$ prediz novas partículas de acordo com

$$x_{t+1|t}^{(i)} = f(x_{t|t}^{(i)}, t) + w_{t|t}^{(i)}$$

$$x_{t+1|t}^{(i)} \sim p(x_{t+1|t} | x_{t|t}^{(i)}), \quad i = 1, \dots, M$$

5. **Calcula-se a estimativa**, que é a média das novas partículas

$$\hat{x} = E\{x_{t+1|t}^{(i)}\}$$

6. **Define** $t = t + 1$ e itera para o passo 2.

Aplicação




Figura: azul: verdade; vermelho: estimado; quadrados verdes: observações.


Desafio da Assimilação de Dados

- Número de observações $\Rightarrow 10^5$ a 10^7 (10^{10}).
- Número de variáveis do modelo $\Rightarrow 10^6$ a 10^8 .

Desafio:

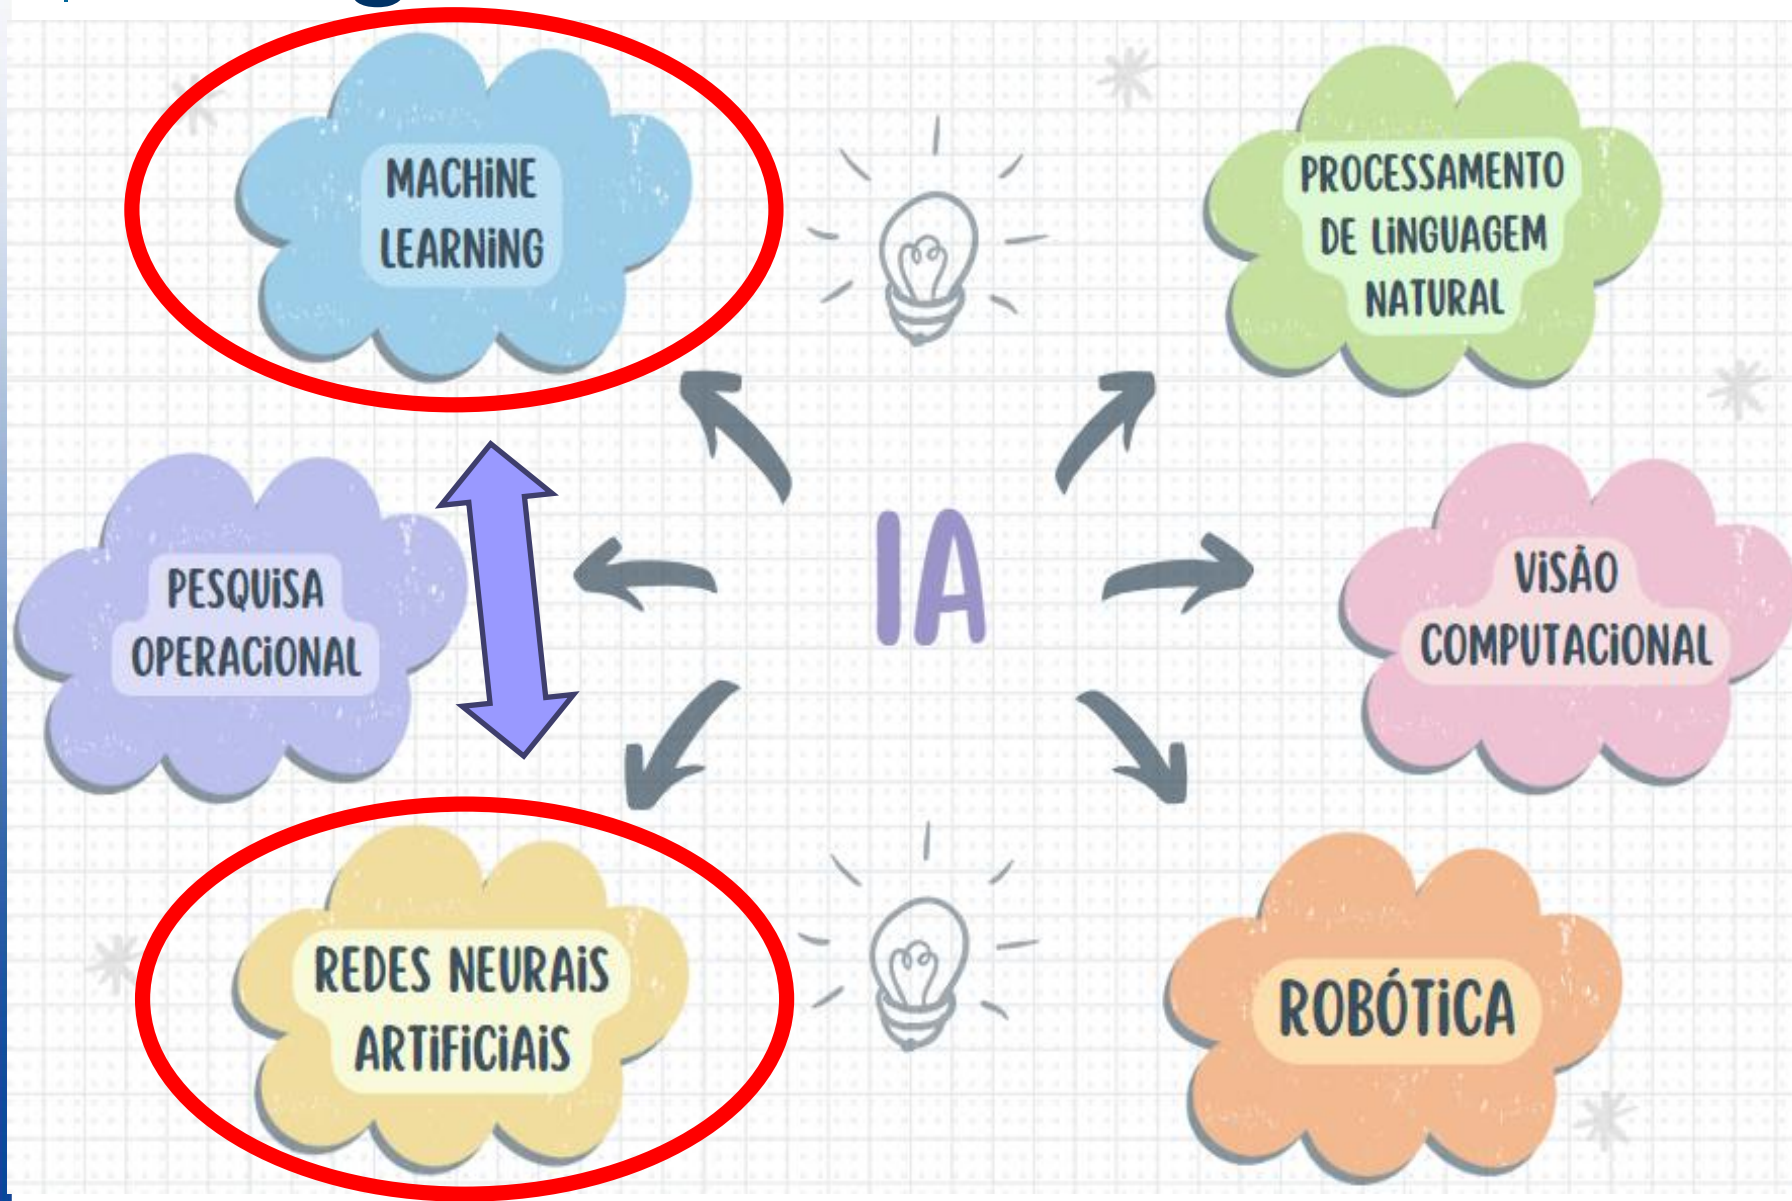
- *Como utilizar os dados disponíveis em modelos com número de grades crescentes e produzir uma análise dentro do tempo disponível na prática operacional?*

Possivelmente ...: Assimilação de dados por Aprendizado de máquina



É uma tecnologia que permite que computadores aprendam a partir de dados, sem serem programados de forma detalhada

Inteligência Artificial



Possivelmente ...

Assimilação de dados por Aprendizado de máquina

Multilayer Perceptron






Figure: Single artificial neuron

$$y_k = \Phi \left(\sum_{j=1}^n w_{kj} x_j + b_k \right)$$

Neurônio Biológico x Neurônio Artificial



PMC como uma Técnica de Assimilação



Para a Assimilação

Mapeamento não linear

$$\mathbf{x}^a = F_w^*(\mathbf{x}^p, \mathbf{y}^o) \Rightarrow \text{RN}$$

Análise com a média ponderada

$$\mathbf{x}^a = \mathbf{x}^p + \mathbf{K}[\mathbf{y}^o - \mathbf{H}(\mathbf{x}^p)] \Rightarrow \text{FK}$$

$$\mathbf{x}^a = p_{et}(\mathbf{y}_t - \mathbf{H}(x_t)) \Rightarrow \text{FP}$$

Minimização

$$\mathbf{x}^a = \min J(\mathbf{x}) \Rightarrow \nabla J(\mathbf{x}) = 0 \Rightarrow \text{Método Variacional}$$

Sistema de Lorenz

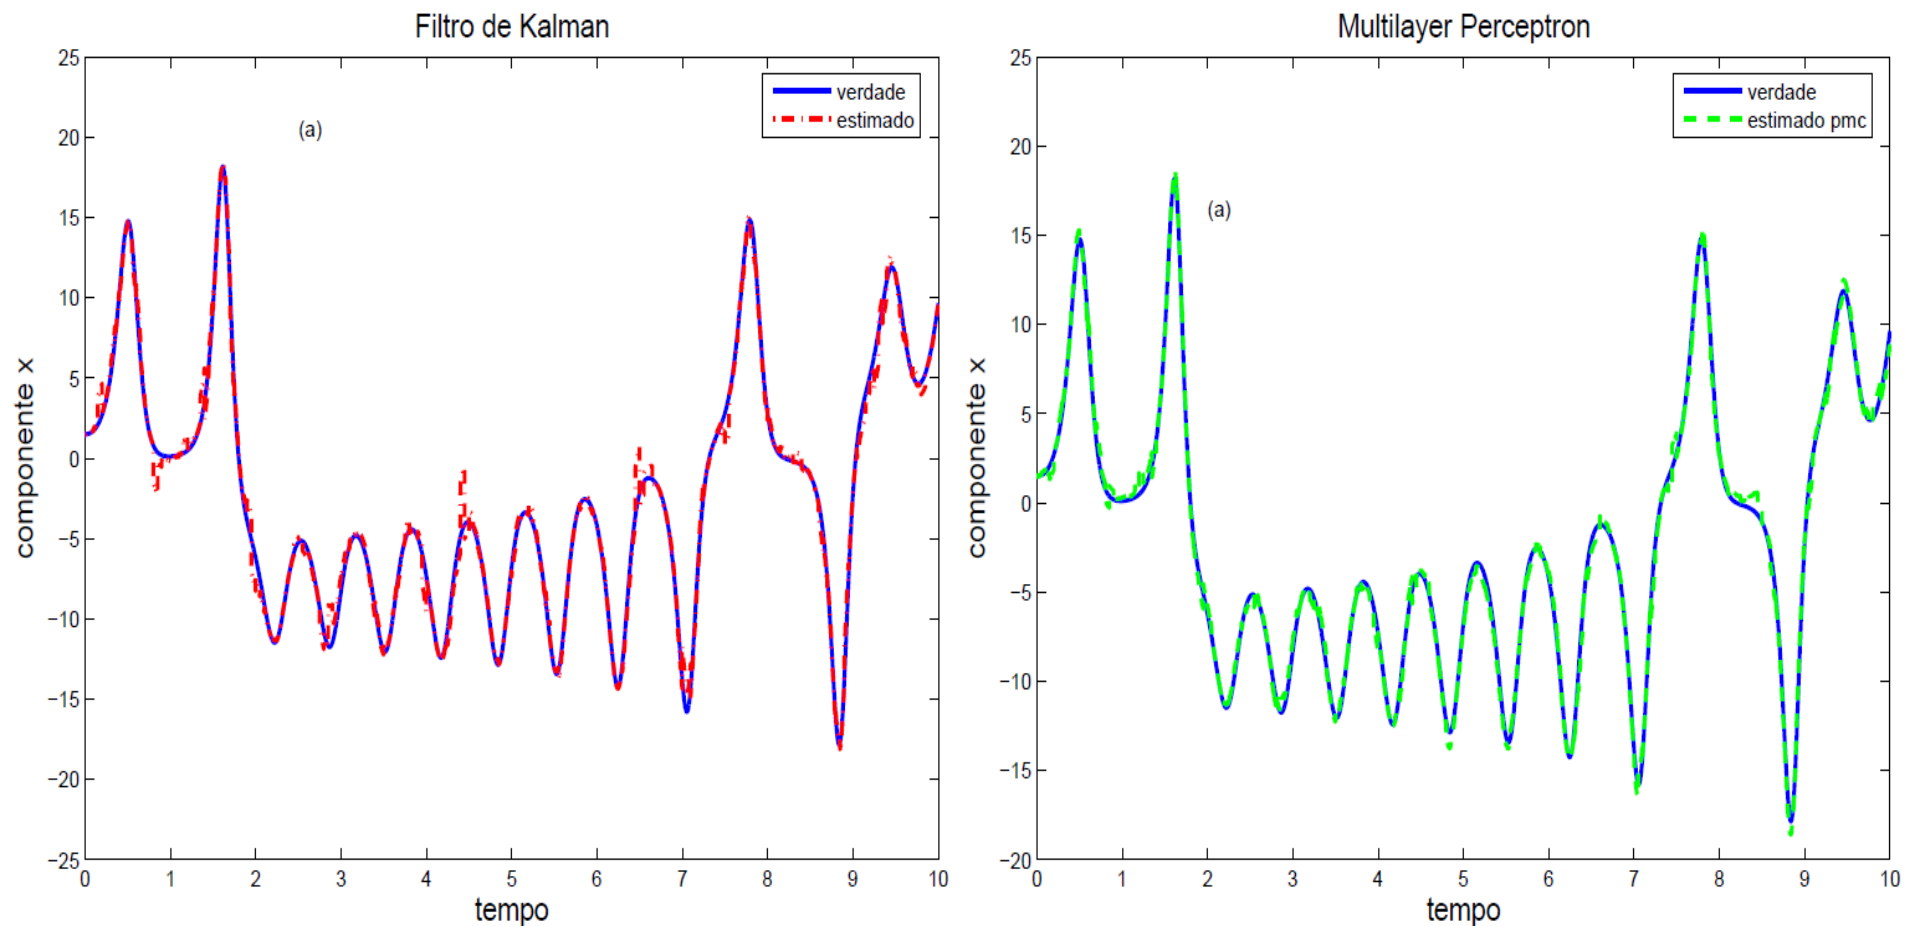


Figura: As observações foram inseridas a cada 50 passos de tempo.

Sistema de Lorenz





Figura: Assimilação de dados a cada 500 passos de tempo, estimativa obtida com o FK: curva tracejada (vermelha) estimado, curva cheia (azul) referência de verdade.

Erro na assimilação

Tabela: Erros de Assimilação.

| freq | $(x + y + z)/3$ | |
|------|-----------------|---------|
| | FK | RNA PMC |
| 12 | 0,5670 | 0,3685 |
| 50 | 0,7583 | 0,3951 |
| 100 | 0,8420 | 0,4729 |
| 250 | 1,1862 | 1,1902 |
| 500 | 2,6655 | 2,5745 |




Figura: eixo x é a frequência das observações e o eixo y é o erro.

Resultados: Sistema de Lorenz

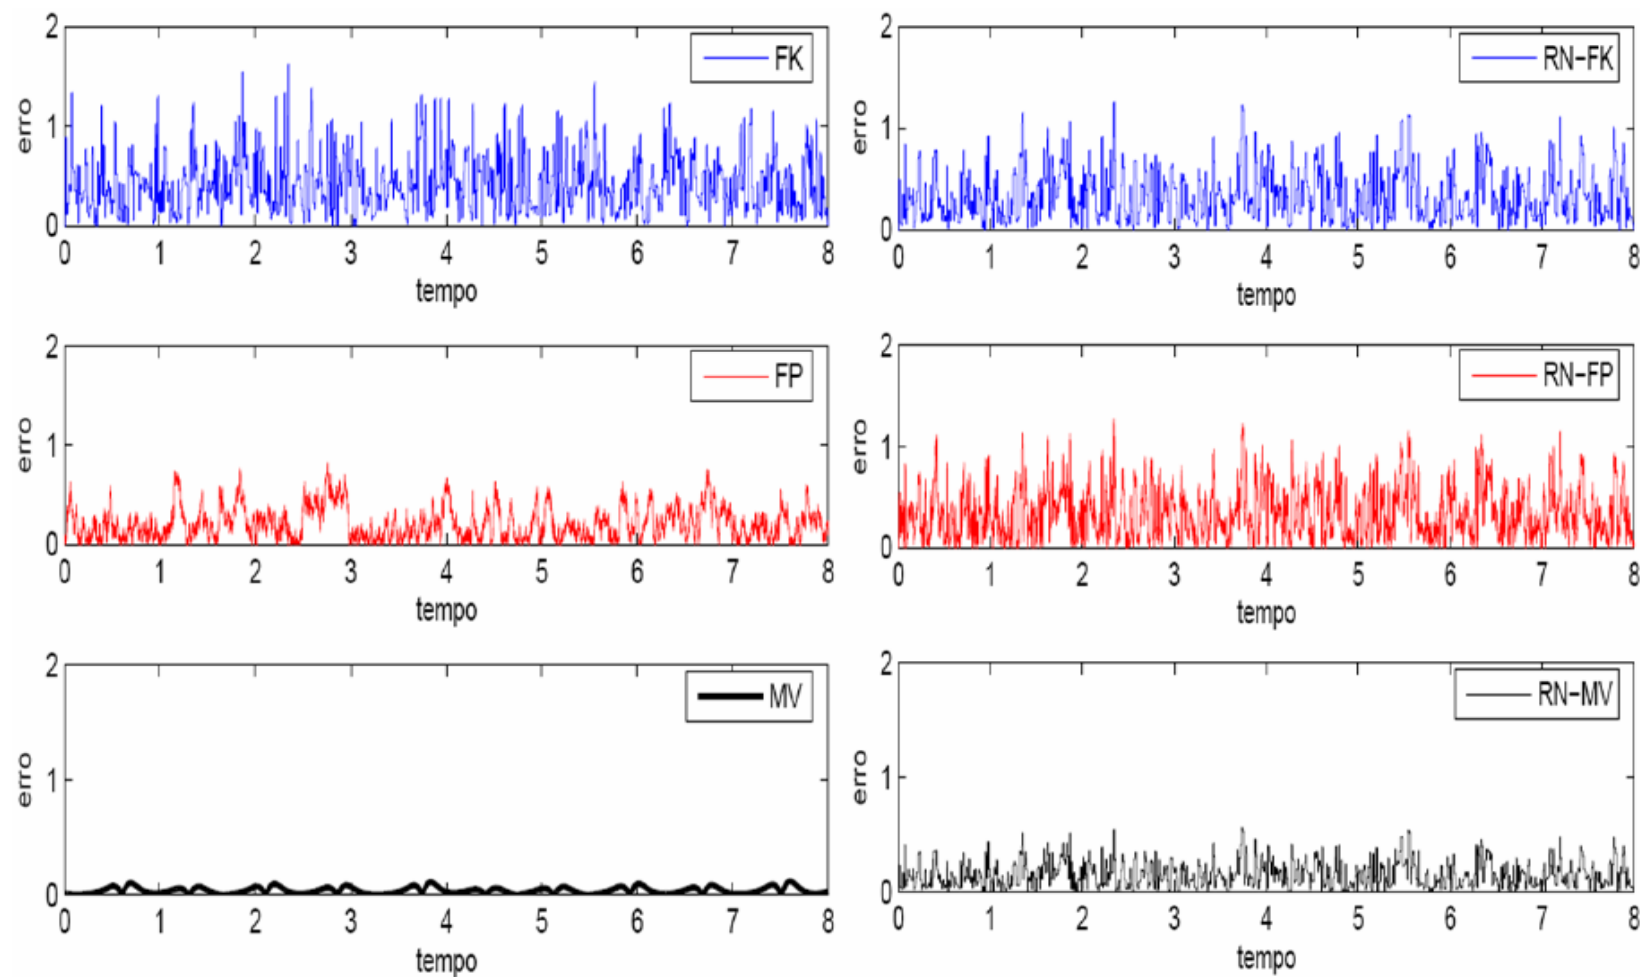


Figura: Gráfico dos erros, com observações a cada 12 passos de tempo.

Modelo 1D

$$\frac{\partial \eta_F}{\partial t} + c \frac{\partial \eta_F}{\partial x} = F(x, t) \quad \text{Equação da onda Linear}$$

- η é o deslocamento;
- c é a constante de velocidade de fase;
- F é uma forçante externa;
- t é o tempo e x é o espaço;

Esta equação também pode ser interpretada como a equação da convecção.

Condição inicial

- Solução analítica da equação de KDV (Korteweg-de Vries)
- Condição de contorno periódica

$$\eta(x, 1) = \eta_0 \frac{1}{\cosh^2[(x - v)/\Delta]}$$

$$\Delta = \sqrt{\frac{12\beta}{\alpha\eta_0}} \text{ e } v = c + \frac{\alpha\eta_0}{3}$$

| Parâmetro | Valor |
|-----------|-------------------------------|
| η_0 | -60 m |
| c | 2,42 m^{-1} |
| α | $-1,62 \times 10^{-2} s^{-1}$ |
| β | $1,46 \times 10^5 m^3 s^{-1}$ |
| Δ | 1340 m |
| v | 2,75 ms^{-1} |

Modelo





Figura: Evolução temporal de η com suas projeções nos eixos: x distância; y : tempo; z : amplitude do *soliton*.

Assimilação





Equações de água-rasa

$$\frac{\partial u}{\partial t} - f v + g \frac{\partial q}{\partial x} + r_u u = F_u$$


$$\frac{\partial v}{\partial t} + f u + g \frac{\partial q}{\partial y} + r_v v = F_v$$

$$\frac{\partial q}{\partial t} + H \left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} \right) + r_q q = 0$$





Elevacao a partir da superficie do mar Trajetoria RNA e Representer (t=10)



CPU time

Assimilação de dados SW2D (circulação oceânica)

| | KF | Rvar | ANN-KF | ANN-Rvar | speed |
|---------|---------------|--------------|-----------------|------------|-------|
| 100 obs | 79 <i>min</i> | - | 5,00 <i>min</i> | - | 15× |
| 25 obs | 42 <i>min</i> | - | 1,39 <i>min</i> | - | 30× |
| 8 obs | - | 4 <i>min</i> | - | 2 <i>s</i> | 113× |

Publicações

Dynamic Days South America 2010

IOP Publishing

Journal of Physics: Conference Series **285** (2011) 012036

doi:10.1088/1742-6596/285/1/012036

Neural networks for emulation variational method for data assimilation in nonlinear dynamics

Helaine Cristina Morais Furtado

Haroldo Fraga de Campos Velho


Elbert E. N. Macau

Laboratório Associado de Computação e Matemática Aplicada, São José dos Campos, Brasil

E-mail: helaine.furtado@lac.inpe.br, haroldo@lac.inpe.br, elbert@lac.inpe.br

Abstract. Description of a physical phenomenon through differential equations has errors involved, since the mathematical model is always an approximation of reality. For an operational prediction system, one strategy to improve the prediction is to add some information from the real dynamics into mathematical model. This additional information consists of observations on the phenomenon. However, the observational data insertion should be done carefully, for avoiding a worse performance of the prediction. Technical data assimilation are tools to combine data from physical-mathematics model with observational data to obtain a better forecast. The goal of this work is to present the performance of the Neural Network Multilayer Perceptrons trained to emulate a Variational method in context of data assimilation. Techniques for data assimilation are applied for the Lorenz systems; which presents a strong nonlinearity and chaotic nature.

Publicações




[Integral Methods in Science and Engineering](#) pp 47-57 | [Cite as](#)

Adaptive Particle Filter for Stable Distribution

Authors

[Authors and affiliations](#)

H. F. de Campos Velho , H. C. Morais Furtado

Chapter

1

1.6k

Citations Downloads

Abstract

Particle filters are considered as the most robust method in the estimation theory. However, all techniques presented in the literature consider only cases where the data can be described by a probability distribution function (PDF) with all statistical moments well defined. The present chapter a novel particle filter is introduced for estimating a posteriori PDF using a Bayesian scheme. The key issue is to consider an adaptive likelihood function. The scheme generalizes the traditional particle filter approaches. The scheme can be applied to inverse problem, control

Publicações




[Integral Methods in Science and Engineering](#) pp 25-35 | [Cite as](#)

q -Calculus Formalism for Non-extensive Particle Filter

Authors

[Authors and affiliations](#)

Amarisio S. Araújo, Helaine C. M. Furtado, Haroldo F. de Campos Velho 

Chapter

First Online: 19 July 2019

141

Downloads

Abstract

A class of sequential Monte Carlo estimation is frequently called particle filter. This filter belongs to the Bayesian strategy for estimation, where a non-linear and non-Gaussian assumptions can be applied. Here, the Tsallis' distribution, from the non-extensive thermodynamics, is used to design the best likelihood operator. Therefore, no previous likelihood operator is assumed. The new filter formulation will be named as *non-extensive particle filter* (NEx-PF). The distribution estimated by the NEx-PF can compute the standard form of the

Vamos para a Prática????

- Métodos implementados pelo Dr. Amos Lawlees (<https://www.reading.ac.uk/maths-and-stats/staff/amos-lawless>)

- Vamos utilizar a plataforma Google Colab que será conduzida pelo Pesquisador Roberto.



COMPUTAÇÃO
APLICADA



Obrigada!



UNIVERSIDADE FEDERAL DO OESTE DO PARÁ



Laboratório
Nacional de
Computação
Científica

UNIDADE DE PESQUISA DO MCTI

